

**LAPORAN AKHIR PROJEK UAS: ANALISIS
SENTIMEN BERBASIS ASPEK (ABSA) DAN
NAMED ENTITY RECOGNITION (NER)
MENGUNAKAN MACHINE LEARNING DAN
INDOBERT TRANSFER LEARNING**



Dipersiapkan oleh:

Hot Rifaldo Malau (230712537)

Dionisio Raditya Prasmada (230712370)

Lodevick Bintang Saputra (230712386)

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS ATMA JAYA YOGYAKARTA**

2026

1. BAB I: PENDAHULUAN

1.1. Latar Belakang

Ulasan pelanggan pada platform digital mengandung informasi berharga mengenai kualitas produk, harga, pelayanan, dan lokasi suatu bisnis. Namun, analisis sentimen secara global (keseluruhan kalimat) sering kali gagal menangkap informasi spesifik karena sebuah ulasan bisa mengandung sentimen positif untuk satu aspek tetapi negatif untuk aspek lainnya. Oleh karena itu, diterapkan **Analisis Sentimen Berbasis Aspek (ABSA)** melalui dua pendekatan: **Proyek A (Klasifikasi Multilabel)** untuk memetakan aspek-sentimen global, dan **Proyek B (Named Entity Recognition - NER)** untuk mendeteksi batas frasa kata (*boundary tokens*) yang merujuk pada entitas aspek tertentu.

1.2. Rumusan Masalah

- Bagaimana cara membangun model klasifikasi multilabel yang optimal untuk mendeteksi kombinasi aspek dan sentimen yang tidak seimbang (imbalanced labels)?
- Bagaimana mengatasi fenomena subword tokenization pada arsitektur Deep Learning IndoBERT untuk tugas Token Classification (NER)?
- Bagaimana mengintegrasikan kedua model ke dalam sebuah aplikasi web yang interaktif dan memiliki jembatan logika yang sinkron?

1.3. Tujuan Proyek

- Membangun sistem otomatisasi ekstraksi opini pelanggan berbasis kecerdasan buatan.
- Membandingkan performa model Problem Transformation pada klasifikasi multilabel dan mengevaluasi ketangguhan transfer learning model berbasis Transformer (IndoBERT).
- Mendeploy model ke dalam dashboard interaktif berbasis Streamlit menggunakan akselerasi GPU lokal.

2. BAB II: METODOLOGI DAN ALUR EKSPERIMEN

2.1. Partisi Data (Data Splitting)

Dataset kelompok Kelp3 dibagi secara konsisten menggunakan rasio 70% Data Train, 15% Data Validation, dan 15% Data Test. Data validasi digunakan sebagai komparator objektif selama proses tuning, sementara data test dikunci rapat hanya untuk evaluasi final akhir.

2.2. Alur Pemrosesan Proyek A (Klasifikasi Multilabel)

1. Preprocessing: Case folding, pembersihan karakter aneh/emoji, dan penanganan ketimpangan label menggunakan pembobotan kelas (`class_weight='balanced'`).

2. Feature Engineering: Ekstraksi fitur berbasis frekuensi menggunakan TF-IDF Vectorizer.
3. Pemodelan: Menggunakan strategi Problem Transformation Binary Relevance yang dikombinasikan dengan algoritma Logistic Regression.

2.3. Alur Pemrosesan Proyek B (Named Entity Recognition)

Konversi Koordinat ke Tag BIO: Mengonversi posisi karakter span menjadi format token kata berlabel B- (Begin), I- (Inside), dan O (Outside).

Subword Alignment: Menyelaraskan hasil potongan tokenizer khusus IndoBERT (misal kata berimbuhan yang terpotong menjadi ###nya) menggunakan nilai indeks `word_ids()` serta memberikan label penalti -100 pada token spesial agar diabaikan oleh fungsi loss PyTorch.

Pemodelan: Fine-tuning arsitektur Pre-trained indobenchmark/indobert-base-p1 untuk tugas `AutoModelForTokenClassification`.

3. BAB III: HASIL EKSPERIMEN DAN ANALISIS PERFORMA

3.1. Hasil Evaluasi Final Proyek A (Multilabel)

Model Binary Relevance + Logistic Regression dipilih sebagai model terbaik berdasarkan pencapaian metrik tertinggi pada data validasi. Berikut hasil pengujian pada data Test:

- Macro F1-Score: 0.4262 (Sangat baik dalam mengenali kelas-kelas minoritas/langka).
- Subset Accuracy: Kriteria ketat di mana seluruh label dalam satu kalimat harus tertebak dengan benar secara mutlak.

3.2. Hasil Evaluasi Final Proyek B (NER)

Evaluasi menggunakan library `seqeval` dengan aturan ketat `Strict Chunk Matching`.

Model terbaik dikunci pada Epoch 3 dengan F1-Score menyeluruh sebesar 0.46.

Berikut adalah rincian performa per entitas aspek:

Kategori Entitas	Precision	Recall	F1-Score	Support
PLACE	0.33	0.39	0.36	332
PRICE	0.52	0.54	0.53	122
PRODUCT	0.47	0.53	0.50	1101
PROMOTION	0.00	0.00	0.00	42
Micro Avg	0.43	0.49	0.46	1597

3.3. Analisis Overfitting (Hyperparameter Tuning)

Selama proses pelatihan IndoBERT 5 Epoch, ditemukan gejala overfitting yang jelas setelah melewati Epoch 3:

Training Loss: 0.88 → 0.79 → 0.68 → 0.67 → 0.52

Validation Loss: 0.83 → 0.82 → 0.87 → 0.91 → 0.95

Meskipun *Training Loss* terus menurun hingga Epoch 5, *Validation Loss* justru melambung naik sejak Epoch 3. Strategi penyimpanan model menggunakan `load_best_model_at_end=True` terbukti berhasil menyelamatkan model dengan cara memotong langkah latihan dan mengunci bobot optimal pada Epoch 3 (saat F1-Score mencapai titik kulminasi tertinggi sebesar 0.4649).

4. BAB IV: ANALISIS KESALAHAN (ERROR ANALYSIS)

4.1. Kasus Salah Prediksi NER 1: Contextual Blindness

- Teks: "Sangat bagus..."
- Label Asli: B-PRODUCT | Prediksi AI: B-PLACE
- Analisis: Frasa "Sangat bagus" bersifat sangat generik. Tanpa adanya subjek kata benda yang jelas di dekatnya, model melakukan generalisasi bias ke arah kelas PLACE karena pola kata sifat tersebut lebih dominan berdekatan dengan ulasan lokasi pada data latihan.

4.2. Kasus Salah Prediksi NER 2: Pelanggaran Sintaks BIO

- Teks: "Belajar bikin gerabah..."
- Label Asli: B-PRODUCT, I-PRODUCT
- Prediksi AI: O (pada kata Belajar), lalu I-PRODUCT (pada kata bikin).
- Analisis: Model mengalami boundary error di mana ia gagal mengenali token awal frasa, namun berhasil mengenali kelanjutan frasanya. Munculnya tag I-langsung setelah tag O melanggar hukum formal tata bahasa BIO, membuktikan model masih membutuhkan regulasi struktural yang lebih ketat.

5. BAB V: IMPLEMENTASI DAN DEMO APLIKASI WEB

Aplikasi web berhasil dideploy menggunakan framework Streamlit (`Kelp3_app.py`) dan memanfaatkan arsitektur paralel dari GPU lokal NVIDIA

5.1. Jembatan Logika Aplikasi (Core Correlation)

Aplikasi mengintegrasikan kedua proyek secara berdampingan untuk menyajikan penalaran AI yang transparan:

1. Kolom kiri (Proyek A) mengekstrak sentimen global (misal: PRODUCT_POSITIVE, PRICE_POSITIVE, PLACE_POSITIVE).
2. Kolom kanan (Proyek B) membongkar bukti fisik kata di dalam kalimat yang mendasari keputusan tersebut (misal: memetakan frasa "harganya pas di kantong" sebagai entitas PRICE dengan skor keyakinan 92.88%).

6. BAB VI: KESIMPULAN

1. Kombinasi Binary Relevance dan Logistic Regression efektif memberikan performa yang seimbang pada data ulasan multilabel yang mengalami ketimpangan kelas ekstrem.
2. Model IndoBERT Token Classification mampu mengenali entitas ulasan bahasa Indonesia gaul secara presisi, namun sangat sensitif terhadap overfitting apabila dilatih melebihi 3 epoch pada jumlah data berskala menengah.
3. Ketiadaan data latih yang memadai pada entitas PROMOTION menyebabkan model sama sekali gagal mengenali entitas tersebut (F1-Score: 0.00), membuktikan bahwa kuantitas data berbanding lurus dengan kecerdasan ekstraksi fitur model Deep Learning.

Nama Anggota	NIM	Kontribusi Projek (Job Desk)	Status
Hot Rifaldo Malau	230712537	Setup Environment GPU, Token Alignment, Training IndoBERT NER, Coding App Streamlit	Selesai
Dionisio Raditya Prasmada	230712370	Pemisahan Data (Splitting), Visualisasi EDA Notebook, Pembuatan Laporan Akhir	Selesai
Lodevick Bintang Saputra	230712386	Preprocessing Data, Pelatihan Model Multilabel Proyek A, Perekaman Video Demo	Selesai